

基于内容的推荐 & 基于知识的推荐（L2）完全总结

本章包含两大块：基于内容的推荐（Content-based）和基于知识的推荐（Knowledge-based）。通俗来说，前者是"给我推和我之前喜欢的东西相似的东西"，后者是"根据我的明确需求告诉我什么适合我"。

一、基于内容的推荐

1.1 核心思想

不需要任何其他用户的数据，仅凭物品的内容特征和用户的历史偏好来推荐。

"Show me more of the same what I've liked."

需要的要素：

- 物品的内容信息（如流派、关键词、作者）
- 用户偏好档案（从历史行为中学习）

1.2 "内容"是什么？

类型	说明
结构化内容	每个物品由相同的属性集描述（如标题、类型、价格、作者）
非结构化内容	自由文本描述（如新闻文章、网页内容）

1.3 物品表示：TF-IDF

TF-IDF 是信息检索中最著名的权重方法：

$$\text{TF-IDF}(\text{词项}, \text{文档}) = \text{TF}(\text{词频}) \times \text{IDF}(\text{逆文档频率})$$

- TF（词频）**：词项在文档中出现多少次
- IDF（逆文档频率）**：稀有词更重要，常见词（如"的""是"）权重低

每个文档表示为一个 TF-IDF 实值向量 $\in \mathbb{R}^{|V|}$ ，文档相似度用余弦相似度衡量：

$$\cos(q, d) = (q \cdot d) / (|q| \times |d|)$$

1.4 向量空间模型的改进

为减少噪声、提高效果：

改进方法	说明
去停用词	删除"a"、"the"等几乎所有文档都出现的词
词干还原	将"went""go""stemming"归一为"go""stem"
截断	只保留前n个最关键的词（如前100个）
特征选择	用 χ^2 、互信息等指标筛选"好"关键词
短语作为词项	"United Nations"比"United"+"Nations"更有意义

1.5 用户档案构建

根据用户已评分的物品，构建用户画像向量：

$$\text{用户偏好} = \text{其评分物品的内容向量加权平均}$$

1.6 基于内容的最近邻推荐

与协同过滤思路相同，但相似度基于内容计算：

1. 找到用户未见过的商品中与已喜欢商品最相似的 Top-K
2. 用邻居评分加权预测
3. 可用于短期兴趣/后续故事推荐

1.7 Rocchio 算法

用于信息检索/物品推荐的相关反馈：

$$Q(i+1) = \alpha * Q(i) + \beta * (D+ \text{中所有文档向量平均}) - \gamma * (D- \text{中所有文档向量平均})$$

- α ：原始查询权重
- β ：正反馈权重
- γ ：负反馈权重

1.8 线性分类器

用机器学习方法（线性分类器、SVM、朴素贝叶斯）学习用户偏好：

$$w_1x_1 + w_2x_2 > b \rightarrow \text{分类函数}$$

1.9 基于内容推荐的局限性

问题	说明
内容有限/太短	短文本难以提取有效特征
多媒体难以处理	图像、视频等内容难以自动提取
不理解语义	"素食者喜欢的东西"会错误匹配到餐饮广告
过度专门化	推荐列表全是同质内容 → 信息茧房
需要训练数据	必须有一定数量评分才能建立模型

二、基于知识的推荐

2.1 为什么需要？

场景	说明
评分稀少	产品刚上市没有评分
时间敏感	五年前对手机的评分已过时
明确需求	用户想直接指定要求（如"黑色"）

CF 和基于内容的问题：依赖大量历史数据。基于知识的方法不依赖评分，直接根据用户需求推荐。

2.2 两大路线

基于约束的推荐（Constraint-based）

核心：基于明确定义的推荐规则。

知识库包含：

- 变量：用户模型特征 + 物品目录
- 约束条件：
 - 硬约束（必须满足，如"笔记本必须有SSD"）
 - 软约束/加权约束（可以弹性满足，如"最好有触摸屏"）

三个子任务：

1. 找到满足所有约束的物品 → 无解时需要约束松弛
2. 找满足最大加权约束集的物品
3. 按软约束权重对物品排序

基于案例的推荐（Case-based）

核心：基于相似度度量检索物品。

- 相似度：物品属性值到用户需求的相似程度
- 用户可表达"越高越好" (More is Better) 或"越低越好" (Less is Better)

2.3 约束满足问题 (CSP)

将推荐问题形式化为 CSP：

求解：找到变量取值，使所有约束条件被满足
输入：用户需求 SRS、知识库 KB、商品目录 I
输出：满足条件的物品元组

合取查询：用 AND 组合多个条件，在商品目录中筛选。

2.4 与用户交互

- 向导式对话：逐步收集用户需求
- 默认值选择：静态默认值、依赖默认值、衍生默认值
- 可解释性：能解释"为什么推荐这个"——这是基于知识方法的核心优势

2.5 约束松弛 (Constraint Relaxation)

当找不到满足所有约束的物品时：

诊断 → 修复流程：

需求无解 → 计算最小冲突集 → 生成诊断 → 计算修复建议

QuickXPlain 算法（核心思想：分而治之）：

- 递归将约束集一分为二
- 检测每个子集是否满足约束
- 直到找到最小冲突集
- 优点：避免检查整个约束集合，复杂度显著降低

2.6 物品排序：多属性效用理论 (MAUT)

对物品各属性打分 (1-10)，按用户对各维度的重视程度加权求和：

$$\text{效用}(\text{user}, \text{item}) = \sum (\text{用户对维度的权重} \times \text{物品在该维度的效用})$$

2.7 动态评判 (Dynamic Critiquing)

结合关联规则挖掘动态生成复合评判：

循环：

- 1. ItemRecommend → 推荐最相似物品
 - 2. CompoundCritiques → 用Apriori挖掘复合评判
 - 3. UserReview → 用户评判，更新查询
- 直到用户满意

复合评判：用户可同时提出多个修改意见（如"价格更低 + 像素更高"），比单一评判效率更高。

2.8 基于知识推荐的应用现状

场景	方法
电商导购、企业采购、金融配置	基于约束
房产、旅游定制、医疗决策	基于案例
大规模高频推荐（短视频、电商首页）	已转向协同过滤 + 深度学习

三、L2 知识全景图

推荐系统

- ├─ 基于协同过滤（CF） ─ 群体智慧
- ├─ 基于内容（Content-based） ─ 物品特征
 - ├─ TF-IDF 向量表示
 - ├─ 余弦相似度
 - ├─ 用户画像构建
 - ├─ 最近邻 / Rocchio / 线性分类器
 - └─ 局限：内容有限、过度专门化、信息茧房
- └─ 基于知识（Knowledge-based） ─ 明确需求
 - ├─ 基于约束（Constraint-based）
 - ├─ CSP 问题
 - ├─ 约束松弛 / QuickXPlain
 - └─ MAUT 排序
 - └─ 基于案例（Case-based）
 - ├─ 相似度度量
 - ├─ 动态评判
 - └─ 复合评判

四、真题级要点速记

- 基于内容的核心是 TF-IDF + 余弦相似度 + 用户画像加权平均。
- 过度专门化（overspecification）是内容推荐最大局限，导致信息茧房。
- 基于知识推荐解决评分稀少、时间敏感、明确需求三类问题。
- QuickXPlain 算法用分而治之找最小冲突集，避免全量搜索。

MAUT 通过多属性加权求和实现物品排序。

动态评判结合关联规则挖掘，复合评判比单一评判效率更高。

基于知识推荐的优势是**可解释性**——能说清楚"为什么推荐这个"。