

混合推荐系统 & 推荐系统评价（L3）完全总结

本章包含两大块：混合推荐系统（Hybrid）和推荐系统评价（Evaluation）。通俗来说，前者是"把多种方法拧成一股绳"，后者是"怎么判断我的推荐系统到底好不好"。

一、混合推荐系统

1.1 为什么要混合？

方法	优势	劣势
协同过滤	利用群体智慧，无需领域知识	新物品冷启动；稀疏性问题
基于内容	无冷启动；可解释	过度专门化；需要内容特征
潜在因子模型	精准建模	计算复杂

混合的核心思想：各取所长，避其所短。

1.2 混合设计三大类别

① 模型整合（Model Hybridization）

设计一个统一模型，内部融合多种算法思想。

代表：**SVD++** —— 矩阵分解 + 最近邻思想的融合。

② 并行混合（Parallel Hybridization）

多个算法同时运行，输出合并：

方法	说明
加权法	各算法预测结果加权求和，权重通过实验或学习确定
切换法	根据条件切换使用哪个算法（如评分少用内容，评分多用CF）
混合型	在用户界面层面分组展示不同算法结果

加权混合示例：

$$\text{最终预测} = \beta \times \text{Rec}_1(\text{分数}) + (1-\beta) \times \text{Rec}_2(\text{分数})$$

权重如何确定？

- 经验实验（试不同的组合）
- 动态调整（根据训练集表现优化）

- 自举法（Bootstrap）

注意：不同算法的分数尺度可能不同，需要分数归一化后再加权。

③ 流水线式混合（Pipelined Hybridization）

算法串联，前一阶段的输出作为后一阶段的输入：

方式	说明
级联（Cascade）	先过滤明显不相关的物品，再精细排序
细化（Refinement）	用更复杂模型重新排序前一阶段的输出

优势：分层过滤 + 效率较高

不足：错误传播（前一步错了后面跟着错）+ 调参困难

1.3 混合方法汇总

方法	类别	核心思想
SVD++	模型整合	MF + Nearest-neighbor
加权混合	并行	多算法输出线性加权
切换混合	并行	根据条件切换算法
级联	流水线	先粗筛后精排
Content-Boosted CF	混合	用内容预测填充CF缺失评分

二、推荐系统评价

2.1 评价的两大维度

维度	说明
离线评价（Offline）	用已有数据集模拟，在实验室完成
线上评价（Online）	真实环境 A/B 测试，观察真实用户行为

学术界92%以上的论文仅用离线评价。但离线≠真实，差距很大。

2.2 评分预测指标

指标	公式	特点
MAE	$\sum p_i - r_i / n$	线性惩罚所有偏差
RMSE	$\sqrt{[\sum (p_i - r_i)^2 / n]}$	对大偏差更敏感

MAE = 0.46, RMSE = 0.75

2.3 Top-N 推荐指标

混淆矩阵

	实际正	实际负
推荐正	TP (命中)	FP
未推荐正	FN	TN

Precision（准确率） & Recall（召回率）

Precision = TP / (TP + FP) = 命中数 / 推荐数
Recall = TP / (TP + FN) = 命中数 / 实际正样本总数

- Precision 高 → 推荐的东西"准", 但可能漏掉很多
- Recall 高 → 覆盖广, 但可能推了很多不相关的

F1 指标

调和平均, 平衡 Precision 和 Recall:

$F1 = 2 \times \text{Precision} \times \text{Recall} / (\text{Precision} + \text{Recall})$

NDCG（归一化折损累积增益）

核心理想：排名越靠前的命中越重要。

$DCG@K = \sum (rel_i / \log_2(i+1))$
NDCG = DCG / IDCG (理想排序下的DCG)

MAP（平均准确率）

每个相关项出现位置的准确率之和:

$AP = \sum (P(k) \times rel(k)) / \text{相关物品总数}$
MAP = 所有用户 AP 的平均

2.4 实验设计方法

方法	说明
随机划分	随机分训练/测试集，不考虑时间
留一法	每个用户留一个交互作为测试
滑动窗口	训练集随时间向前滑动
固定窗口	训练集大小固定，整体前移
时间抽样	特定时间点前后数据选为测试集
N折交叉验证	将数据分成 N 份，轮流做测试集

2.5 线下评价的常见陷阱

数据泄露（Data Leakage）

问题：测试时间点之后的用户-物品交互被混入训练数据。

- 模型可能推荐"未来才出现的物品"
- 推荐准确性数字好看但无实际意义

原因：学术研究中通常忽略**全局时间线**——实践中有明确的"当前时间 t_c"。

流行度定义的差异

	实践	学术
流行度	动态更新，基于短期数据	静态，基于整个训练集
目标	优化销售和盈利	公平比较算法性能

反直觉的观察

- 历史交互多的用户，推荐反而**相对较差**
- 用近期数据训练，推荐系统性能**显著提升**

训练/测试数据划分的问题

- 训练数据：点击流受页面布局影响（位置偏置）
- 测试数据：用户没有机会点击"只在新推荐模块中出现"的物品
- CTR 指标 ≠ 商业收益

2.6 更可靠的评估方式

全局时间线观察：

- 所有交互按时间排序
- 用时间窗口逐步测试

- 避免数据泄露

2.7 其他评价维度

维度	指标
新鲜度（Novelty）	用户未见物品比例
覆盖率（Coverage）	能推荐多少不同物品
意外性（Serendipity）	出乎意料但用户喜欢
公平性（Fairness）	对不同用户/物品群体是否公平
商业指标	CTR、转化率、GMV

三、L3 知识全景图

混合推荐

- └─ 模型整合：统一模型内部融合（SVD++）
- └─ 并行混合：加权 / 切换 / 混合展示
- └─ 流水线混合：级联（先粗筛后精排）

推荐系统评价

- └─ 离线评价（学术主流）
 - └─ 评分预测：MAE / RMSE
 - └─ Top-N推荐：Precision / Recall / F1 / NDCG / MAP
 - └─ 实验设计：随机划分 / 留一法 / N折交叉验证
 - └─ 陷阱：数据泄露 / 位置偏置 / 全局时间线缺失
- └─ 线上评价（工业实践）
 - └─ A/B测试、用户调研

四、真题级要点速记

- 混合的核心目的：充分利用各算法优势，避免单一方法的缺点。
- 加权混合需要先归一化不同算法的分数尺度，不能直接加权。
- 流水线混合的优势是效率，缺点是错误传播。
- NDCG 核心思想：排名越靠前的命中越有价值（对数衰减）。
- 数据泄露是离线评价最大隐患——测试时间点之后的数据混入训练，导致"推荐未来物品"的荒谬结果。
- MAE vs RMSE：RMSE 对大偏差更敏感（平方惩罚）。
- 反直觉发现：历史交互多的用户推荐反而差；近期数据训练效果更好。