

链接分析（L5）完全总结

链接分析的核心是利用网页之间的链接关系来判断网页的重要性。最经典的应用就是 Google 的 PageRank 算法。通俗来说就是"被越多重要的网页链接的网页，越重要"。

一、PageRank

1.1 基本思想

PageRank 模拟一个"随机游走者"在互联网上随机点击链接浏览网页：

- 每个网页有一个 PR 值（PageRank 值）
- PR 值在整个网络中按链接传递
- 被更多重要网页指向的网页，获得更高的 PR 值

1.2 随机跳转（Teleport）

解决两个问题：

问题	说明
死胡同（Dead Ends）	网页没有出链接，游走者困住
蜘蛛陷阱（Spider Traps）	所有出链接指向内部网页集合，游走者无法跳出

解决方案：每步以概率 β 沿链接走，以 $1-\beta$ 随机跳转到任意网页（称为 Teleport）。

1.3 PageRank 算法

$$r = (\beta \times M \times r) + (1-\beta) \times a$$

- M：转移矩阵（每列是概率分布）
- a：跳转向量（均匀分布）
- β ：阻尼因子（通常设为0.8或0.85）

迭代计算直到收敛。

1.4 PageRank 的问题

- 只衡量普遍重要性，不考虑特定主题
- 使用单一重要性度量
- 容易受到链接垃圾（Link Spam）攻击

二、主题敏感的 PageRank（Topic-Specific PageRank）

2.1 核心思想

不对所有网页平等跳转，而是跳转到**特定主题**的相关网页。

跳转集 S = 某主题的权威网页集合（如体育类网页）

2.2 有偏随机游走

当游走者需要跳转时，从**主题相关网页集合 S** 中选择目标，而不是均匀跳转到任意网页。

2.3 发现主题向量

使用 **DMOZ 开放目录** 的16个顶级类别（如 Arts、Business、Sports）构建不同主题的 PageRank 向量。

三、邻接性度量

3.1 什么是"好"的邻接性度量？

需要考虑的因素：

- **多个连接**：两点之间多条路径
- **直接和间接连接**：不仅直接相连，也可能间接相连
- **节点度数**：高度数节点是重要枢纽
- **多条独立路径**：提高网络鲁棒性

3.2 最短路径的问题

不理想的原因：

- 忽略了一度节点的存在（大家其实都和 E、F、G 相连）
- 无法区分多重关系

四、Pixie：Pinterest 实时推荐

4.1 Pinterest 的数据结构

Pinterest 可看作一个巨大的二部图：

- **Pin（图钉）**：用户保存的内容
- **Board（画板）**：用户的收藏夹
- **边**：Pin 被保存到 Board

4.2 Pixie 随机游走

给定一个或多个查询 Pin，通过随机游走推荐相关 Pin：

1. 从查询 Pin 集合 Q 开始
2. 随机选择一个邻居 Board
3. 从 Board 随机选择一个 Pin
4. 增加该 Pin 的访问计数
5. 以概率 α 重启回 Q

4.3 优化

- **加权边**：游走倾向特定语言/特征的边
- **多查询 Pin**：并行运行 + 合并计数
- **Early Stopping**：前1000个 Pin 至少有20次访问时就停止
- **图剪枝**：去掉超热门 Pin（被几百万 Board 保存的 Pin 会分散信号）

4.4 性能

- **50毫秒**内完成推荐
- 单机可并行运行 **1500**个随机游走
- 全图 **17亿**节点、**30亿**边 可装入单机内存

五、TrustRank：对抗链接垃圾

5.1 网络垃圾（Web Spam）

垃圾网页通过**链接农场（Link Farms）**互相链接，人为提升 PageRank。

5.2 TrustRank 的核心思想

基本原则：好网页很少指向垃圾网页。

1. 人工筛选一批**种子网页**（可信网页，如 .edu、.gov）
2. 从种子网页开始，通过链接**传播信任值**
3. 信任值随距离增加而衰减
4. 信任被分割：出链越多，每个出链分到的信任越少

5.3 信任传播公式

$$\text{trust}(p \rightarrow q) = \beta \times \text{trust}(p) / |\text{出链数}|$$

5.4 种子集选择

- 按 PageRank 高分选择（好网页不太可能有极低的 PageRank）
 - 使用受控域名（.edu、.gov）增加可靠性
-

六、L5 知识全景图



七、真题级要点速记

- 随机跳转（Teleport）的作用是解决死胡同和蜘蛛陷阱，保证随机游走者不会"困住"。
- 主题敏感 PageRank 的核心变化：从均匀跳转到跳转到特定主题的权威网页集合。
- Pixie 能在 50ms 内完成推荐得益于 Early Stopping（不必走完全部路径）和图剪枝（去掉超热门 Pin）。
- TrustRank 的基本原则：好网页很少指向垃圾网页——这是整个算法的核心假设。
- Trust 传播的两个特性：距离衰减（离种子越远信任越低）+ 信任分割（出链越多每条分得越少）。