

图表示学习（L7）完全总结

图表示学习的核心是将网络中的节点映射到低维向量空间，使得嵌入空间中的相似性反映原始网络中的结构相似性。通俗来说就是"把网络结构编码成向量，这样就能用数学方法处理图了"。

一、为什么需要图嵌入？

1.1 挑战

图的结构非常复杂：

- 没有网格那样的空间局部性
- 没有固定的节点排序
- 经常是动态的，且具有多模态特征

1.2 核心目标

将每个节点映射到 d 维空间中的一个点：

- 节点之间的嵌入相似性 $\approx$ 原始网络中的相似性
- 支持节点分类、链接预测、聚类等多种下游任务

二、嵌入节点的两个关键问题

2.1 编码器（Encoder）

最简单：浅层编码（嵌入查找）：

$$\text{ENC}(u) = Z[:, u] \quad \# Z \text{ 是嵌入矩阵}$$

每个节点对应嵌入矩阵中的一列。

2.2 节点相似性（Similarity）

这是最关键的问题：

相似性类型	说明
邻接相似性	两个节点有边直接相连
二阶相似性	两个节点的邻域结构相似
结构相似性	两个节点在网络中的"角色"相似（如都是 Hub）

三、随机游走嵌入 (Random Walk Embeddings)

3.1 核心思想

- 从节点 u 出发进行**随机游走**，收集访问到的节点集合 $N_R(u)$
- 优化嵌入，使得：给定 u ，预测 $N_R(u)$ 中的节点

3.2 优化目标

$$\begin{aligned} \min L &= -\log P(N_R(u) \mid z_u) \\ &\approx \sum_{\{v \in N_R(u)\}} \log P(v \mid z_u) \end{aligned}$$

3.3 为什么用随机游走？

- 表达能力**：结合局部和高阶邻居信息（多跳邻居也能到达）
- 效率**：只考虑共现节点对，不需要计算所有节点对

3.4 负采样 (Negative Sampling)

完整 softmax 代价高，用负采样近似：

$$\log \sigma(z_u \cdot z_v) + \sum_{i=1}^k E_{n_i \sim P_n} [\log \sigma(-z_u \cdot z_{n_i})]$$

- 从背景分布 P_n 中采样 k 个负样本
- 用 Sigmoid 区分正负样本
- $k = 5 \sim 20$ 为常用范围

四、DeepWalk vs node2vec

4.1 DeepWalk

- 使用**无偏随机游走**（等概率选择邻居）
- 简单但相似性概念受限（只看局部结构）

4.2 node2vec：可调相似性

通过两个参数控制游走策略：

参数	作用	低参数值的行为
p (返回参数)	返回到前一个节点	降低则更倾向于折返（BFS 倾向）
q (出入参数)	向外扩散的程度	降低则更倾向于深入探索（DFS 倾向）

BFS 倾向：探索局部邻域 → 捕捉微观结构（社区内部）
DFS 倾向：探索全局结构 → 捕捉宏观视图（社区间关系）

4.3 node2vec 算法

- 1. 对每个节点计算游走概率（含 p、q 参数）
- 2. 从每个节点出发模拟 r 条长度为 l 的随机游走
- 3. 用 SGD 优化负采样目标函数

时间复杂度： **$O(n)$** ，与图边数线性相关。

五、其他随机游走方法

方法	改进方向
metapath2vec	基于节点属性选择游走路径
struct2vec	构建结构相似性图再游走
HARP	层次化图预处理（粗→细粒度）
LINE	直接优化一阶 + 二阶相似性

六、整图嵌入（Graph Embedding）

6.1 方法一：节点嵌入求和/平均

在图上运行标准嵌入方法，然后对所有节点嵌入求和或平均。

6.2 方法二：虚拟节点

引入一个代表整个图的"虚拟节点"，将其连接到图中所有节点，再运行标准嵌入。

七、嵌入的应用

7.1 链接预测

组合两个节点嵌入的方式：

方式	公式
拼接	$g([z_u, z_v])$
逐元素乘积 (Hadamard)	$g(z_u \times z_v)$
求和/平均	$g(z_u + z_v)$
距离	$g(z_u - z_v)$

7.2 节点分类

直接用节点嵌入 z_i 预测标签 $f(z_i)$ 。

八，L7 知识全景图

图表示学习

- ├─ 核心问题
 - ├─ 编码器：浅层查找 ($ENC(v) = Z[:, v]$)
 - └─ 相似性定义：邻接 / 二阶 / 结构相似性
- ├─ 随机游走嵌入
 - ├─ DeepWalk：无偏随机游走
 - ├─ node2vec：可调BFS/DFS倾向（参数p、q）
 - ├─ 负采样优化
 - └─ 应用：链接预测、节点分类
- ├─ 整图嵌入
 - ├─ 节点嵌入求和/平均
 - └─ 虚拟节点法
- └─ 方法选择
 - ├─ 节点分类 → node2vec（微观）
 - └─ 链接预测 → 多跳方法（宏观）

九，真题级要点速记

- node2vec 的 **p** 参数控制返回概率，p 高则游走倾向于在局部探索（BFS）；**q** 参数控制向外扩散，q 低则深入探索（DFS）。
- 负采样将完整 softmax 转化为多个二分类 Sigmoid，在实践中用 k=5~20 个负样本。
- BFS 倾向**的嵌入更反映社区内部微观结构；**DFS 倾向**的嵌入更反映社区间宏观关系。
- 随机游走的优势**：同时捕捉局部和高阶邻居信息，计算效率高。
- 嵌入质量取决于**相似性定义**是否与下游任务匹配——没有一种方法在所有场景最优。