

基于图神经网络的推荐系统（L8）完全总结

本章介绍了 GNN（Graph Neural Networks）在推荐系统中的应用。核心思想是直接在图结构上做消息传递，将协同过滤的高阶连通性、社交关系、知识图谱等信息统一建模。通俗来说就是"把推荐问题看成图，用 GNN 来学习节点表示"。

一、为什么推荐系统需要 GNN

1.1 传统推荐系统的局限

问题	说明
高阶连通性不足	只考虑直接相似用户/物品，无法捕捉多跳关系
监督信号稀疏	用户反馈少（稀疏度常达 99%）
结构化数据利用不足	图结构信息（社交、知识图谱）未被充分利用

1.2 GNN 的优势

- 直接在图结构上操作，通过邻居信息聚合更新节点表示
- 端到端训练：与 node2vec 的两步法（先随机游走再训练嵌入）不同
- 支持节点特征 + 图结构联合学习

1.3 GNN 用于推荐的核心挑战

挑战	说明
图构建	节点/边定义、异构/同构、处理规模
信息传播聚合	邻居集合选择、传播深度
模型优化	损失函数设计、数据采样

二、GNN for 协同过滤

2.1 Q1：GNN 适合 CF 吗？

NGCF（Neural Graph Collaborative Filtering, SIGIR'2019）

核心：将用户-物品交互建模为二部图，通过 GNN 显式编码高阶协同信号。

NGCF 的传播公式：

$$\begin{aligned} m_{u \leftarrow i}^{(l)} &= W_1^{(l)} \cdot e_i^{(0)} + W_2^{(l)} \cdot (e_i^{(0)} \odot e_u^{(0)}) \\ e_u^{(l)} &= \text{LeakyReLU}(m_{u \leftarrow i}^{(l)}) \end{aligned}$$

- 多层堆叠 → 捕捉高阶连通性（如 $u_1 \leftarrow i_2 \leftarrow u_2 \leftarrow i_4$ ）
- 拼接多层嵌入，反映不同连接距离的信息贡献

实验结论：NGCF 在所有数据集上显著优于传统 CF 方法。

2.2 Q2：如何为 CF 定制 GNN？

LightGCN（SIGIR'2020）——大幅简化 NGCF：

NGCF 的操作	LightGCN 处理
特征变换 (W_1, W_2)	去掉（一致性提升）
非线性激活 (LeakyReLU)	去掉（增加训练难度）
自连接 (Self-connection)	去掉（通过层组合隐式实现）
拼接多层嵌入	加权求和（层组合 α_k ）

LightGCN 的传播：

$$e_u^{(k+1)} = \sum_{i \in N_u} \frac{1}{\sqrt{d_u \times d_i}} \cdot e_i^{(k)}$$

- 简化为对称归一化的邻居加权求和
- 训练更快，效果更好

2.3 Q3：如何引入自监督学习？

SGL（Self-supervised Graph Learning, SIGIR'2021）

解决 CF 的三大问题：

- 稀疏监督信号（观察到的交互极少）
- 偏态数据分布（幂律分布，高度数物品影响过大）
- 互动中的噪声（隐式反馈噪声多）

图增强策略：

方法	说明
Node Dropout（ND）	丢弃不同视图中的节点，识别有影响力的节点
Edge Dropout（ED）	丢弃边，捕捉局部结构模式
Random Walk（RW）	层敏感的结构增强

对比损失 (InfoNCE) :

$$L_{ssl} = -\log \sum \exp(\text{sim}(z_u', z_{u''}') / \tau)$$

结合监督损失 (BPR) 和自监督损失 (SSL) , 多任务学习。

三、GNN for 知识图谱推荐

3.1 为什么需要 KG?

- 知识图谱提供物品的外部知识 (属性、关系)
- 协同知识图谱: 用户-物品交互 + 物品-物品知识 → 高阶连通性

3.2 KGAT (Knowledge Graph Attention Network, KDD'2019)

将 KG 融入 GNN:

注意力嵌入传播:

- 从用户到物品, 沿着 KG 路径递归传播嵌入
- 注意力评分衡量不同关系的重要性
- 通过多层传播捕捉高阶连通性 (如 $u_2 \leftarrow_{r_1} i_2 \leftarrow_{r_2} u_1 \leftarrow_{r_1} i_1$)

3.3 KGIN (Knowledge Graph-based Intent Network, WWW'2021)

KGAT 的局限: 没有在细粒度意图级别区分用户-物品关系。

KGIN 的改进:

改进点	说明
用户意图建模	每个意图由 KG 关系分布表示 (注意力组合)
关系路径建模	将关系路径作为信息通道 (而非仅节点聚合)
独立性正则化	不同意图的嵌入应互相区别

四、其他 GNN 推荐场景

4.1 价格感知推荐 (PUP)

- 挑战: 价格意识是隐式的、类别依赖的
- 方法: 双分支 GCN (全局分支 + 类别分支)

4.2 序列推荐 (SURGE, SIGIR'2021)

- 挑战: 长序列中混杂真实兴趣和噪声; 用户偏好随时间漂移

- 方法：
 1. 构建兴趣图（用度量学习找物品相似度）
 2. 兴趣融合图卷积（簇感知 + 查询感知注意力）
 3. 图池化（软聚类，保留动态激活的核心偏好）
 4. GRU 演化建模

4.3 套餐推荐（BGCN, SIGIR'2020）

- 挑战：用户-套餐交互更稀疏（比物品更少）
- 方法：异构图（用户-商品-套餐）层次传播
 - 商品级别传播：用户偏好
 - 套餐级别传播：套餐间替代性
 - Hard Negative 训练

4.4 多行为推荐（MBGCN, SIGIR'2020）

- 挑战：行为强度差异模糊；行为语义多样（互补/可替代）
- 方法：
 - 用户-物品传播：行为感知的加权聚合
 - 物品-物品传播：基于行为共现

4.5 多样性推荐（DGCN, WWW'2021）

- 挑战：准确率-多样性困境；主导类别样本过多
- 方法：
 - GCN 匹配中实现多样化（而非匹配后）
 - 多样化邻居发现（类别直方图倒数加权）
 - 对抗学习（去除物品嵌入中的类别信息）

五，L8 知识全景图

GNN for Recommender Systems

- ├ CF 推荐
 - ├ NGCF: GNN + 高阶协同信号 + 拼接多层嵌入
 - ├ LightGCN: 去特征变换/非线性激活/自连接, 简化GCN
 - └ SGL: 自监督学习 + 图增强 (ND/ED/RW)
- ├ KG 推荐
 - ├ KGAT: 注意力嵌入传播 + 关系感知
 - └ KGIN: 意图建模 + 关系路径建模
- └ 其他场景
 - ├ 价格感知: 双分支GCN (全局 + 类别)
 - ├ 序列推荐: SURGE (兴趣图 + 图池化 + GRU演化)
 - └ 套餐推荐: BGCN (异构图层次传播)

- └ 多行为: MBGCN (行为感知传播)
- └ 多样性: DGCN (匹配中多样化 + 对抗学习)

六, 真题级要点速记

NGCF 的核心: 将协同过滤建模为二部图, 通过 GNN 多层传播显式编码高阶协同信号 ($u_1 \leftarrow i_2 \leftarrow u_2 \leftarrow i_4$)。

LightGCN 的三大简化: 去掉特征变换、去掉非线性激活、去掉自连接 (用层组合替代), 训练更快且效果更好。

SGL 的三种图增强: Node Dropout (识别有影响力节点)、Edge Dropout (捕捉局部结构)、Random Walk (层敏感增强)。

KGIN vs KGAT: KGAT 只建模用户-物品单一关系; KGIN 进一步区分细粒度意图和关系路径。

DGCN 的核心创新: 在匹配阶段就用 GCN 实现多样化 (而非传统 MMR 在匹配后做), 避免了准确率-多样性困境。