

神经重排（L9）完全总结

神经重排是推荐系统中最后一道排序关卡，它接收上游排序阶段的候选列表，用更复杂的模型重新排列，最终呈现给用户。通俗来说就是"把粗排的结果再精挑细选一遍"。

一、工业推荐系统架构

1.1 多阶段推荐管线

工业推荐系统通常分为多个阶段，每个阶段逐步缩小候选范围：

阶段	任务	模型特点
召回（Recall）	从全量物品池中快速召回相关物品	简单高效，多路召回
粗排（Pre-ranking）	高效过滤不相关物品	特征少，模型简单
精排（Ranking）	精确预测用户偏好	特征多，模型复杂，多目标
重排（Re-ranking）	全局最优排列	考虑列表上下文，多目标

核心矛盾：效果 vs 效率的权衡——越往后模型越复杂，能处理的候选越少。

1.2 重排 vs 精排

维度	重排	精排
视角	多变量（整个列表）	单变量（单个物品）
交互	物品间交叉影响	物品独立评分
输出	最优排列（NP-hard）	每个物品的分数
典型方法	Transformer / RNN	DNN / Wide&Deep

二、重排的方法分类

2.1 按目标分类

目标	说明
准确性导向	最大化预测相关性
多样性感知	避免推荐同类物品
公平性感知	避免对特定群体偏见

2.2 按监督信号分类

信号来源	说明	数据来源
观察信号	实际展示列表 + 用户反馈	真实线上日志
反事实信号	假设排列 + 额外评估	反事实排列

三，准确性导向重排

3.1 通过观察信号学习

PRM（Personalized Re-ranking Model, RecSys'2019）

核心结构：

1. **Transformer 编码**：用 Transformer 编码初始列表中所有物品
2. **个性化注入**：将预训练的用户偏好 $p_{\{u,i\}}$ 作为额外输入
3. **输出重排分数**

优势：

- 自注意力能捕捉任意物品对的相互影响
- 比 RNN 更快（可并行处理）

注意力权重可视化发现：

- 女装和女鞋之间注意力高（同品类关联）
- 男装和男鞋之间注意力高
- 价格相近的商品注意力高（对角线深色）

IRGPR（CIKM'2020）

将物品关系（可替代性、互补性）融入图神经网络：

- 构建用户-物品统一异构图
- 物品-物品边：相似、互补、同时购买等关系
- 用 GNN 做消息传递

3.2 观察信号的局限

- 只基于一种排列训练（实际有 $n!-1$ 种未探索）
- 过早评分问题：重排改变了列表上下文

3.3 通过反事实信号学习

Generator-Evaluator 范式

- **生成器 (Generator)**：生成可行排列
- **评估器 (Evaluator)**：评估每个排列的效用
- **目标**：找到最优排列（组合优化问题， $n!$ 复杂度）

效用导向的重排

用 BiLSTM 作为评估器，学习不同排列的效用。

Lambda 损失：可微分的排序优化目标。

四，多目标重排

4.1 多样性感知的重排

DGCN 的思想

- 在匹配阶段用 GCN 实现多样化
- 多样化邻居发现：主导类别（衣服 >> 电子）加权惩罚，偏向稀有类别
- 对抗学习：从物品嵌入中去除类别信息

4.2 公平性感知的重排

- 避免对特定用户群体（性别、职业等）的偏见
- 在重排中显式引入公平性约束

五、商业指标

指标	说明
eCPM	有效千次展示收入
CTR	点击率
LTV	用户生命周期价值
PV / VV	页面浏览量 / 视频播放量

六， L9 知识全景图

神经重排

——多阶段推荐管线

— 召回 (多路, 简单模型)

— 粗排 (高效过滤)

——精排（精确预测，多特征多目标）

└─ 重排 (全局最优排列)

- └─ 准确性导向
 - └─ 观察信号：PRM (Transformer)、IRGPR (GNN)
 - └─ 反事实信号：Generator-Evaluator 范式
- └─ 多目标重排
 - └─ 多样性：DGCN (匹配中多样化)
 - └─ 公平性：重排中引入公平约束
- └─ 商业指标
 - └─ eCPM / CTR / LTV

七，真题级要点速记

重排的核心问题：一次考虑整个列表的排列优化 (NP-hard)，无法穷举 $n!$ 种可能。

PRM 用 Transformer 自注意力捕捉任意物品对的相互影响，且可并行处理，比 RNN 序列建模更快。

观察信号学习的局限：只基于一种排列训练，其余 $n!-1$ 种排列未探索。

Generator-Evaluator 范式是处理反事实信号的标准框架：生成器生成候选排列，评估器评估效用。