

大模型时代的推荐系统（L10）完全总结

本章介绍大语言模型（LLM）在推荐系统中的应用。核心思想是利用 LLM 的语言理解、泛化和推理能力来革新推荐系统。通俗来说就是"让 AI 助手来理解你的需求，给你推荐"。

一、大语言模型（LLM）的三大核心能力

1.1 语言理解与生成

- LLM 能理解用户意图和物品描述
- 生成更贴近人类的自然语言回应
- 充分利用推荐系统中的丰富文本信息

1.2 泛化能力

- 无需微调即可适应各种下游推荐任务
- 通过任务指令（Prompt）或少量示例（Few-shot）实现多任务适配
- 零样本（Zero-shot）推荐成为可能

1.3 推理能力

- 支持复杂的多步推荐决策
- 通过思维链（Chain-of-Thought）提示生成逐步推理
- 可结合外部知识进行深度分析

二、Transformer 基础

2.1 自注意力机制（Self-Attention）

$$\text{Attention}(Q, K, V) = \text{softmax}(QK^T / \sqrt{d_k}) \times V$$

- Query (Q)**：我想要什么
- Key (K)**：我能提供什么
- Value (V)**：实际传递的内容
- 通过 Q 和 K 的相似度决定 V 的加权系数

2.2 多头注意力（Multi-Head Attention）

- 并行执行多个自注意力计算
- 从不同子空间学习不同的关系模式
- 最后拼接所有头的输出

2.3 位置编码

Transformer 没有循环结构，需要额外注入位置信息：

- 绝对位置编码（正弦/余弦）
- 相对位置编码

三、预训练语言模型（PLM）

3.1 自监督预训练任务

任务	说明
MLM（掩码语言模型）	遮盖部分词，让模型预测（BERT 的核心）
NSP（下一句预测）	判断两个句子是否连续
Seq2Seq	给定上文，预测下一个词（GPT 系列）

3.2 ELMo vs BERT vs GPT

模型	架构	特点
ELMo	双层 LSTM	上下文相关词向量，但不够深
BERT	Transformer Encoder	MLM + NSP，双向理解
GPT	Transformer Decoder	自回归语言模型，生成能力强

四、LLM 在推荐系统中的三种应用范式

4.1 预训练（Pre-training）

在推荐数据上继续预训练 LLM，增强其对推荐任务的适配：

- 训练目标：用户行为预测
- 保留 LLM 的通用能力
- 代价：需要大量推荐数据，训练成本高

4.2 微调（Fine-tuning）

用推荐数据对 LLM 进行有监督微调：

方法	说明
全量微调	更新所有参数
PEFT（参数高效微调）	只更新部分参数，如 LoRA

LoRA（Low-Rank Adaptation）：

- 在预训练权重旁边添加低秩矩阵
- 只训练低秩矩阵的参数，大幅降低计算成本

4.3 提示（Prompting）

最轻量方式，直接用 Prompt 引导 LLM：

方法	说明
零样本（Zero-shot）	仅通过指令描述任务
少样本（Few-shot）	提供少量示例
思维链（CoT）	让 LLM 展示推理过程

五、LLM 推荐的具体应用

5.1 评分预测

将用户历史评分、物品信息组合成自然语言描述，让 LLM 预测评分。

5.2 推荐理由生成

为推荐结果生成自然语言解释，增强用户信任：

- "因为你喜欢 X，所以推荐 Y"
- 基于用户评论中的关键词生成解释

5.3 冷启动推荐

新用户/新物品没有交互数据时：

- 用 LLM 分析物品描述，匹配用户兴趣
- 零样本推荐，无需历史数据

5.4 对话式推荐

结合对话系统，实现多轮交互式推荐：

- 用户不断补充需求
- LLM 在对话中逐步缩小推荐范围

六、代表性模型

模型	年份	核心贡献
BERT4Rec	2019	将 BERT 用于序列推荐
RecBots	-	对话式推荐框架
ChatGPT-Rec	2023	初步探索 ChatGPT 做推荐
InstructRec	2023	指令调优的推荐 LLM

七、挑战与展望

7.1 当前挑战

挑战	说明
计算成本	LLM 推理代价极高，难满足线上延迟要求
幻觉问题	LLM 可能生成不存在的物品描述
时效性	LLM 知识有截止日期，推荐需要实时数据
评估困难	传统离线指标不适用于 LLM 推荐

7.2 未来趋势

- 检索增强生成（RAG）：结合向量数据库，解决知识时效性问题
- 模型压缩：蒸馏、量化，使 LLM 可在端侧部署
- 多模态：结合图像、视频，提升推荐体验
- 个性化 Prompt：为不同用户生成定制化提示词

八、L10 知识全景图

大模型推荐

├─ LLM 三大核心能力

├─ 语言理解与生成

├─ 泛化能力（零样本/少样本）

└─ 推理能力（思维链）

├─ Transformer 基础

├─ 自注意力 (Q, K, V)

├─ 多头注意力

└─ 位置编码

└─ 三种应用范式

- | — 预训练（继续预训练推荐数据）
- | — 微调（LoRA 等 PEFT 方法）
- | — 提示（零样本/少样本/思维链）
- 应用场景
 - | — 评分预测
 - | — 推荐理由生成
 - | — 冷启动推荐
 - | — 对话式推荐
- 挑战
 - | — 计算成本
 - | — 幻觉问题
 - | — 知识时效性

九，真题级要点速记

三种范式的成本：提示 < 微调 < 预训练。提示最轻量，微调次之，预训练最重。

LoRA 通过添加低秩矩阵而非全量更新，实现高效的参数微调。

思维链（CoT）让 LLM 展示逐步推理过程，提升复杂推荐决策的质量。

RAG（检索增强生成）是解决 LLM 知识时效性问题的核心方案。

BERT4Rec 的核心：用 BERT 的 MLM 预训练目标做序列推荐，区别于 GPT 的自回归方式。